


TOMMY. DISPENSA DI MATEMATICA

STATISTICA DESCRITTIVA

Media, mediana, moda, deviazione standard e rappresentazione dei dati



Liceo Scientifico • Olimpiadi & TOLC

Media Aritmetica • Mediana • Moda • Varianza e Deviazione Standard • Rappresentazioni Grafiche

TEORIA + PRATICA

FONDAMENTI TEORICI, CON UN APPROCCIO OPERATIVO E INTUITIVO

Dalla necessità di sintetizzare i dati alle proprietà, verificate e spiegate, degli indici statistici

1 INTRODUZIONE E MOTIVAZIONE INTUITIVA

1.1 Un problema antico: sintetizzare l'informazione

Immagina di dover descrivere, con una sola parola o con un solo numero, l'andamento di un'intera classe in una verifica di matematica, l'altezza di mille individui, oppure il reddito di un'intera nazione. In tutti questi casi ci troviamo di fronte a una **massa di dati** — spesso centinaia, migliaia o milioni di osservazioni — che il nostro cervello non è in grado di percepire e confrontare simultaneamente. Eppure, quotidianamente, prendiamo decisioni basate proprio su sintesi di questo tipo: *“la media della classe è stata sufficiente”, “il traffico oggi è nella norma”, “l’inflazione media di quest’anno è stata del 3%”*.

La **Statistica Descrittiva** nasce esattamente da questa esigenza: fornire un insieme di strumenti matematici per *ridurre* un insieme numeroso e disordinato di dati a poche grandezze significative (gli *indici statistici*), senza per questo perdere le informazioni essenziali sulla loro natura — dove si concentrano, quanto sono dispersi, come sono distribuiti.

È importante chiarire fin da subito la differenza rispetto ad altri rami dell'indagine matematica sui dati: la statistica descrittiva *non formula previsioni* e non assegna probabilità a eventi futuri (questo è compito della statistica inferenziale e del calcolo delle probabilità, argomenti di studi successivi); essa si limita a **fotografare, sintetizzare e rappresentare** l'insieme di dati che abbiamo effettivamente osservato.

1.2 Cenni storici: dai censimenti alla nascita della statistica moderna

L'esigenza di raccogliere e sintetizzare dati è antichissima quanto la civiltà organizzata:

- Già nell'antico Egitto e in Mesopotamia venivano condotti **censimenti** della popolazione e del bestiame per finalità fiscali e militari; il termine stesso *“statistica”* affonda le proprie radici nell'italiano *statista* (uomo di Stato) e nel latino *status*: da questa radice, nel Settecento, lo studioso tedesco Gottfried Achenwall coniò il termine *Statistik*, poi diffuso in tutta Europa a testimonianza del legame originario tra questa disciplina e l'amministrazione pubblica.
- Nel 1662 il mercante londinese **John Graunt** pubblicò le *Natural and Political Observations upon the Bills of Mortality*, un'analisi sistematica dei registri di mortalità di Londra: fu il primo a estrarre da dati grezzi delle **regolarità numeriche**

(tassi di mortalità per età, differenze tra i sessi), gettando le basi del metodo statistico moderno.

- Nel XIX secolo l'astronomo e matematico belga **Adolphe Quetelet** introdusse il celebre concetto di *"uomo medio"* (*l'homme moyen*), applicando per la prima volta in modo sistematico la media aritmetica allo studio dei fenomeni sociali e biologici (altezza, peso, criminalità), e osservando come molte grandezze umane si distribuissero secondo una curva a campana.
- Parallelamente, **Carl Friedrich Gauss** e **Pierre-Simon Laplace**, studiando gli errori di misura nelle osservazioni astronomiche, formalizzarono la *curva degli errori* (l'odierna distribuzione normale o gaussiana) e osservarono che la media aritmetica delle misure ripetute costituisce, sotto ipotesi ragionevoli, la stima "migliore" del valore vero di una grandezza fisica.

Da questo intreccio di esigenze pratiche (censimenti, assicurazioni, controllo di qualità) e di curiosità scientifica nasce, tra Ottocento e Novecento, la **Statistica** come disciplina autonoma, con un proprio linguaggio e propri strumenti di calcolo, che oggi andiamo a costruire con la massima chiarezza possibile.

1.3 Il problema pratico che introduce gli indici di sintesi

Consideriamo un esempio concreto, che ci accompagnerà per tutto il capitolo. Un insegnante ha corretto la verifica di matematica di 15 studenti, ottenendo i seguenti voti (in decimi):

4, 5, 5, 6, 6, 6, 7, 7, 7, 7, 8, 8, 9, 9, 10.


Elencare quindici numeri non è, di per sé, un'informazione *utile*: se un genitore chiede *"come è andata la classe?"*, l'insegnante non risponderà recitando la lista dei voti, ma sintetizzerà l'informazione con affermazioni del tipo:

- *"In media la classe ha preso un buon sette"* → nasce l'esigenza di un **indice di posizione centrale** (dove si concentrano i dati?).
- *"I voti sono abbastanza omogenei, quasi tutti tra il 5 e il 9"* → nasce l'esigenza di un **indice di variabilità** (quanto sono dispersi i dati attorno al centro?).
- *"Ecco il grafico con il numero di studenti per ciascun voto"* → nasce l'esigenza di una **rappresentazione grafica** che renda immediatamente visibile la forma della distribuzione.

Il compito di questo capitolo è costruire, in modo operativo e sempre motivato, gli strumenti che rispondono a queste tre esigenze: **indici di posizione** (media, mediana, moda), **indici di variabilità** (campo di variazione, varianza, deviazione standard) e **tecniche di rappresentazione grafica** (tabelle, istogrammi, diagrammi a barre e a torta, box-plot).

1.4 Prima rappresentazione grafica: fissare l'intuizione

Prima di introdurre qualunque formula, osserviamo la distribuzione dei voti dell'esempio precedente in un diagramma a barre, dove sull'asse orizzontale riportiamo i possibili voti e sull'asse verticale il numero di studenti che ha ottenuto ciascun voto (la *frequenza assoluta*, concetto che formalizzeremo tra poco).



Anche senza calcolare ancora nulla, il grafico comunica immediatamente ciò che decine di numeri in fila non riuscirebbero a trasmettere con la stessa efficacia: la distribuzione è *concentrata* attorno ai voti 6–7 e *ragionevolmente simmetrica*. È proprio questa intuizione visiva che la trattazione seguente tradurrà in numeri precisi.

2 TRATTAZIONE TEORICA E OPERATIVA

2.1 Terminologia di base della statistica descrittiva

Prima di introdurre gli indici numerici è indispensabile fissare, senza ambiguità, il vocabolario della disciplina.

DEFINIZIONE 2.1: Popolazione, Unità Statistica e Campione

Si definisce **popolazione statistica** l'insieme completo degli elementi (persone, oggetti, eventi) su cui si intende condurre un'indagine. Ogni singolo elemento della popolazione è detto **unità statistica**. Quando risulta impossibile o troppo oneroso osservare l'intera popolazione, si osserva un suo sottoinsieme rappresentativo, detto **campione**, di numerosità N .

ESEMPIO

Se l'obiettivo è studiare l'altezza di tutti gli studenti italiani, la *popolazione* è l'insieme di tutti gli studenti d'Italia; un singolo studente è una *unità statistica*; i 15 studenti della nostra classe, se scelti a rappresentare un gruppo più ampio, costituirebbero un *campione*.

DEFINIZIONE 2.2: Carattere Statistico e Modalità

Si definisce **carattere** (o *variabile statistica*) la proprietà oggetto di studio, rilevata su ciascuna unità statistica. I valori o le categorie che il carattere può assumere sono dette **modalità**. Un carattere si dice:

- **qualitativo**, se le modalità sono categorie non numeriche; si distingue in:
 - *nominale*, se le modalità non ammettono un ordinamento naturale (es. colore degli occhi, sesso, marca di un'automobile);
 - *ordinale*, se le modalità ammettono un ordinamento ma non una vera distanza numerica (es. titolo di studio, giudizio "scarso/sufficiente/buono/ottimo");
- **quantitativo**, se le modalità sono espresse da numeri, con le sottocategorie:
 - *discreto*, se può assumere solo valori isolati (es. numero di fratelli, voto in decimi);
 - *continuo*, se può assumere, almeno in linea di principio, un qualunque valore reale in un intervallo (es. altezza, peso, tempo di percorrenza).

ATTENZIONE — PERCHÉ LA DISTINZIONE È CRUCIALE

Come vedremo, la **moda** è calcolabile per *qualunque* tipo di carattere (anche nominale), la **mediana** richiede almeno un ordinamento (quindi caratteri ordinali o quantitativi), mentre la **media aritmetica** ha senso solo per caratteri *quantitativi*, poiché richiede di sommare e dividere valori numerici. Applicare la

media a un carattere qualitativo (ad esempio calcolare “la media” dei colori degli occhi) è un errore concettuale, non solo di calcolo: lo vedremo con un controesempio nella Sezione 3.

DEFINIZIONE 2.3: Frequenza Assoluta, Relativa, Percentuale e Cumulata

Sia N il numero totale di unità statistiche osservate, e siano $x_1, x_2, \dots, x_k$ le k modalità distinte assunte dal carattere. Si definisce:

- **frequenza assoluta** n_i della modalità x_i : il numero di unità statistiche che presentano tale modalità. Sommando le frequenze assolute di tutte le modalità si ottiene sempre il totale delle osservazioni:

$$n_1 + n_2 + \dots + n_k = N;$$

- **frequenza relativa** f_i della modalità x_i : il rapporto

$$f_i = \frac{n_i}{N}, \quad \text{con } 0 \leq f_i \leq 1 \quad \text{e} \quad f_1 + f_2 + \dots + f_k = 1;$$

- **frequenza percentuale**: la frequenza relativa espressa in punti percentuali, $f_i\% = f_i \cdot 100$;
- **frequenza cumulata** N_i (ha senso definirla solo se le modalità sono *ordinabili*, cioè per caratteri quantitativi o ordinali): il numero di unità statistiche con modalità minore o uguale a x_i , cioè la somma di tutte le frequenze assolute fino a quella considerata:

$$N_i = n_1 + n_2 + \dots + n_i.$$

L'insieme organizzato di modalità e frequenze corrispondenti si dice **tabella di frequenza** (o *distribuzione di frequenza*).

ESEMPIO — TABELLA DI FREQUENZA DEI VOTI

Organizziamo i 15 voti dell'esempio guida in una tabella di frequenza.

x_i (voto)	n_i (freq. ass.)	f_i (freq. rel.)	$f_i\%$	N_i (cumulata)
4	1	0.067	6.7%	1
5	2	0.133	13.3%	3
6	3	0.200	20.0%	6
7	4	0.267	26.7%	10
8	2	0.133	13.3%	12
9	2	0.133	13.3%	14
10	1	0.067	6.7%	15
Totale	$N = 15$	1.000	100%	—

Si noti come la somma di tutte le frequenze assolute dia $15 = N$, e la somma di tutte le frequenze relative dia 1, in accordo con la Definizione 2.3; inoltre l'ultima frequenza cumulata coincide sempre con N ($N_7 = 15$), poiché per definizione *tutte* le unità hanno modalità minore o uguale alla massima.

2.2 Indici di posizione centrale

Gli **indici di posizione centrale** (o di *tendenza centrale*) hanno lo scopo di individuare un singolo valore rappresentativo attorno al quale i dati tendono a distribuirsi. I tre indici classici — media, mediana e moda — rispondono a criteri diversi, che analizzeremo sia sul piano operativo che su quello del “perché funzionano così”.

2.2.1 La media aritmetica

DEFINIZIONE 2.4: Media Aritmetica Semplice

Dati N valori numerici $x_1, x_2, \dots, x_N$ (non necessariamente distinti), si definisce **media aritmetica** il numero

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_N}{N} \quad (\text{la somma di tutti i dati, divisa per il loro numero}).$$

DEFINIZIONE 2.5: Media Aritmetica Ponderata (per dati in tabella di frequenza)

Se i valori distinti sono $x_1, \dots, x_k$ con frequenze assolute $n_1, \dots, n_k$ (con $n_1 + \dots + n_k = N$), la media aritmetica si calcola come **media ponderata**

$$\bar{x} = \frac{n_1 x_1 + n_2 x_2 + \dots + n_k x_k}{N} = f_1 x_1 + f_2 x_2 + \dots + f_k x_k,$$

dove ogni modalità x_i è “pesata” con la propria frequenza. Non è una nuova definizione, ma semplicemente una riscrittura più rapida della media semplice, ottenuta raggruppando gli addendi uguali.

ESEMPIO — EQUIVALENZA DELLE DUE FORMULE

Applichiamo la formula ponderata alla tabella di frequenza dei voti:

$$\bar{x} = \frac{1 \cdot 4 + 2 \cdot 5 + 3 \cdot 6 + 4 \cdot 7 + 2 \cdot 8 + 2 \cdot 9 + 1 \cdot 10}{15} = \frac{104}{15} \approx 6.93.$$

Il risultato coincide, come deve essere, con quello ottenuto sommando direttamente i 15 voti e dividendo per 15: $\frac{4+5+5+6+6+6+7+7+7+7+8+8+9+9+10}{15} = \frac{104}{15} \approx 6.93$.

TEOREMA 2.1: La somma degli scarti dalla media è sempre nulla

Se calcoliamo lo **scarto** di ogni dato dalla media (cioè la differenza $x_i - \bar{x}$) e sommiamo tutti questi scarti, il risultato è sempre 0:

$$(x_1 - \bar{x}) + (x_2 - \bar{x}) + \cdots + (x_N - \bar{x}) = 0.$$

DIMOSTRAZIONE. Raggruppiamo separatamente i dati e le medie:

$$(x_1 - \bar{x}) + (x_2 - \bar{x}) + \cdots + (x_N - \bar{x}) = (x_1 + x_2 + \cdots + x_N) - \underbrace{(\bar{x} + \bar{x} + \cdots + \bar{x})}_{N \text{ volte}}.$$

Per la Definizione 2.4, la somma di tutti i dati è $x_1 + x_2 + \cdots + x_N = N\bar{x}$; anche il secondo gruppo, essendo $\bar{x}$ ripetuto N volte, vale $N\bar{x}$. Quindi:

$$(x_1 - \bar{x}) + (x_2 - \bar{x}) + \cdots + (x_N - \bar{x}) = N\bar{x} - N\bar{x} = 0.$$

■

ATTENZIONE — INTERPRETAZIONE

Questo fatto giustifica il nome “baricentro” spesso attribuito alla media: esattamente come il baricentro fisico di un sistema di punti materiali di ugual massa, la media è il punto di equilibrio attorno al quale gli scarti positivi e negativi si compensano esattamente. Se i dati non sono tutti uguali, allora non possono essere tutti sopra (o tutti sotto) la media: la media lascia sempre almeno un dato sopra di sé e almeno uno sotto.

TEOREMA 2.2: La media rende minima la somma dei quadrati degli scarti

Fissiamo i dati $x_1, \dots, x_N$ e proviamo a scegliere un numero c qualsiasi con cui confrontarli, calcolando la somma

$$S(c) = (x_1 - c)^2 + (x_2 - c)^2 + \cdots + (x_N - c)^2.$$

Tra tutti i possibili valori di c , quello che rende $S(c)$ più piccola possibile è esattamente $c = \bar{x}$: nessun altro numero fa meglio della media.

DIMOSTRAZIONE. L'idea è scrivere ciascuno scarto $x_i - c$ “passando” per la media $\bar{x}$:

$$x_i - c = (x_i - \bar{x}) + (\bar{x} - c).$$

Eleviamo al quadrato entrambi i membri, usando lo sviluppo del quadrato di un binomio $(A + B)^2 = A^2 + 2AB + B^2$:

$$(x_i - c)^2 = (x_i - \bar{x})^2 + 2(x_i - \bar{x})(\bar{x} - c) + (\bar{x} - c)^2.$$

Scriviamo questa relazione per ciascuno degli N dati (con $i = 1, 2, \dots, N$) e somme membro a membro tutte le N righe ottenute:

$$S(c) = \left[(x_1 - \bar{x})^2 + \cdots + (x_N - \bar{x})^2 \right] + 2(\bar{x} - c) \left[(x_1 - \bar{x}) + \cdots + (x_N - \bar{x}) \right] + \underbrace{\left[(\bar{x} - c)^2 + \cdots + (\bar{x} - c)^2 \right]}_{N \text{ volte}}.$$

Il primo gruppo di parentesi quadre è, per definizione, $S(\bar{x})$. Il secondo gruppo è nullo per il Teorema 2.1 (la somma degli scarti dalla media vale 0). Il terzo gruppo è la somma di N addendi tutti uguali a $(\bar{x} - c)^2$, quindi vale $N(\bar{x} - c)^2$. Otteniamo dunque, per ogni scelta di c :

$$S(c) = S(\bar{x}) + N(\bar{x} - c)^2.$$

Poiché $N(\bar{x} - c)^2$ è sempre maggiore o uguale a zero (è un quadrato moltiplicato per $N > 0$), risulta immediatamente $S(c) \geq S(\bar{x})$ per ogni c , con l'uguaglianza $S(c) = S(\bar{x})$ possibile solo quando $N(\bar{x} - c)^2 = 0$, cioè quando $c = \bar{x}$. Dunque $\bar{x}$ è l'unico valore che rende $S(c)$ minima. ■

ATTENZIONE — PERCHÉ QUESTA DIMOSTRAZIONE FUNZIONA SENZA STRUMENTI AVANZATI

Si noti che il ragionamento precedente usa solo lo sviluppo del quadrato di un binomio e il Teorema 2.1: nessuno strumento più sofisticato. Questa proprietà di minimo non è un mero esercizio formale: è il motivo profondo per cui, come vedremo nel Paragrafo 2.3, si sceglie di misurare la variabilità dei dati tramite la somma dei quadrati degli scarti *dalla media* (e non da un altro valore): la media è, per costruzione, il punto che rende tale somma la più piccola possibile.

2.2.2 La mediana

DEFINIZIONE 2.6: Mediana

Ordiniamo i dati dal più piccolo al più grande. Si definisce **mediana** Me il valore che si trova esattamente a metà di questa lista ordinata:

- se il numero di dati N è **dispari**, esiste un unico dato "di mezzo" (quello che occupa la posizione $\frac{N+1}{2}$ nella lista ordinata): la mediana è quel dato;
- se N è **pari**, non esiste un singolo dato di mezzo, ma due (quelli nelle posizioni $\frac{N}{2}$ e $\frac{N}{2} + 1$): la mediana è la loro media, cioè la loro somma divisa per 2.

In altre parole, la mediana lascia (almeno) il 50% dei dati alla sua sinistra e (almeno) il 50% alla sua destra.

ESEMPIO — CALCOLO DELLA MEDIANA — N DISPARI

Nell'esempio guida, $N = 15$ (dispari), quindi la posizione centrale è $\frac{15+1}{2} = 8$. I dati ordinati sono

$$\underbrace{4, 5, 5, 6, 6, 6, 7}_{7 \text{ dati}}, \boxed{7}, \underbrace{7, 7, 8, 8, 9, 9, 10}_{7 \text{ dati}}$$

quindi $Me = 7$ (l'ottavo dato): esattamente 7 dati precedono e 7 dati seguono il valore centrale.

ESEMPIO — CALCOLO DELLA MEDIANA — N PARI

Consideriamo le altezze (in cm), già ordinate, di $N = 6$ giocatori di una squadra di pallavolo:

$$178, 182, \boxed{185}, \boxed{190}, 193, 198.$$

Essendo $N = 6$ pari, i due valori centrali occupano le posizioni $\frac{6}{2} = 3$ e $\frac{6}{2} + 1 = 4$, cioè 185 e 190. Dunque

$$Me = \frac{185 + 190}{2} = 187.5 \text{ cm},$$

un valore che, come si osserva, *non coincide con nessuna altezza effettivamente misurata*: per N pari la mediana è in generale una media di due dati, non necessariamente uno dei dati originali. Se invece il quarto giocatore fosse alto, come il terzo, 185 cm (anziché 190), i due valori centrali sarebbero entrambi 185, e la mediana coinciderebbe esattamente con un dato osservato: $Me = 185 \text{ cm}$.

Una proprietà notevole della mediana. Così come la media rende minima la somma dei *quadrati* degli scarti (Teorema 2.2), la mediana ha un'analogha proprietà di ottimalità: è il valore c che rende minima la somma delle *distanze assolute* dai dati,

$$T(c) = |x_1 - c| + |x_2 - c| + \cdots + |x_N - c|.$$

A differenza della proprietà della media, questa non si dimostra facilmente con un calcolo algebrico diretto (richiederebbe strumenti che vedremo più avanti nel percorso di studi); possiamo però **verificarla numericamente** su un caso concreto, e capire intuitivamente perché è vera.

ESEMPIO — VERIFICA NUMERICA

Prendiamo i dati ordinati 2, 5, 6, 9, 13 ($N = 5$, dispari): la mediana è $Me = 6$. Calcoliamo $T(c)$ per $c = Me = 6$ e per un paio di valori vicini, a titolo di confronto:

c	somma delle distanze assolute	$T(c)$
5	$ 2 - 5 + 5 - 5 + 6 - 5 + 9 - 5 + 13 - 5 = 3 + 0 + 1 + 4 + 8$	16
6	$ 2 - 6 + 5 - 6 + 6 - 6 + 9 - 6 + 13 - 6 = 4 + 1 + 0 + 3 + 7$	15
7	$ 2 - 7 + 5 - 7 + 6 - 7 + 9 - 7 + 13 - 7 = 5 + 2 + 1 + 2 + 6$	16
9	$ 2 - 9 + 5 - 9 + 6 - 9 + 9 - 9 + 13 - 9 = 7 + 4 + 3 + 0 + 4$	18

Il valore più piccolo si ottiene esattamente per $c = Me = 6$: spostandosi anche di una sola unità in un senso o nell'altro, la somma delle distanze aumenta.

ATTENZIONE — L'INTUIZIONE: PERCHÉ CONVIENE FERMARSI ESATTAMENTE ALLA MEDIANA

Immagina di muovere c lentamente verso destra, partendo da un valore piccolo. Ogni volta che c supera un dato, quel dato passa dal "davanti" al "dietro" rispetto a c : la sua distanza da c , che stava diminuendo, comincia ad aumentare. Muoversi verso destra fa *diminuire* la distanza da tutti i dati che restano ancora a destra di c , e fa *aumentare* la distanza da tutti i dati che si sono già lasciati a sinistra. Conviene quindi continuare a muoversi verso destra fintanto che i dati ancora a

destra sono più numerosi di quelli già superati a sinistra: la somma totale delle distanze continua a scendere. Ci si deve fermare esattamente nel punto in cui il numero di dati a sinistra e a destra si equilibra: e questo punto, per definizione, è proprio la mediana.

ATTENZIONE — CONFRONTO CON LA PROPRIETÀ DELLA MEDIA

Abbiamo quindi due proprietà “gemelle”: la **media** minimizza la somma dei quadrati degli scarti (Teorema 2.2), mentre la **mediana** minimizza la somma dei valori assoluti degli scarti. Questa differenza non è solo estetica: elevare al quadrato “penalizza” molto di più i grandi scarti rispetto al semplice valore assoluto, ed è questo il motivo per cui, come vedremo nella Sezione 3, la media è molto più sensibile ai valori anomali (*outlier*) rispetto alla mediana.

2.2.3 La moda

DEFINIZIONE 2.7: Moda

Si definisce **moda** M_o la modalità (o le modalità) a cui corrisponde la **massima frequenza assoluta** (equivalentemente, la massima frequenza relativa). Una distribuzione si dice:

- **unimodale**, se esiste un'unica modalità di frequenza massima;
- **bimodale** (o *multimodale*), se due (o più) modalità condividono la medesima frequenza massima;
- **amodale**, se tutte le modalità hanno la stessa frequenza (ad esempio, tutti i valori distinti e non ripetuti), rendendo la moda non significativa.

ESEMPIO

Nell'esempio guida, la modalità con frequenza assoluta massima è $x = 7$ (con $n = 4$ studenti, si veda la tabella di frequenza): la distribuzione è *unimodale*, con $M_o = 7$. Si osservi che, in questo caso, moda e mediana coincidono ($M_o = M_e = 7$), mentre la media è leggermente inferiore ($\bar{x} \approx 6.93$): una lieve asimmetria a sinistra della distribuzione dei voti (più valori bassi isolati che alti).

ATTENZIONE — UNICITÀ DELLA MODA PER I CARATTERI QUALITATIVI

La moda è l'unico indice di posizione centrale calcolabile anche per un carattere *qualitativo nominale* (ad esempio, il colore di capelli più frequente in una classe), poiché la sua definizione richiede soltanto di *contare*, non di ordinare né di sommare le modalità.

2.2.4 Confronto e scelta dell'indice più opportuno

I tre indici di posizione centrale, pur rispondendo tutti alla stessa domanda generale (“dove si concentrano i dati?”), hanno proprietà molto diverse in termini di **robustezza**, cioè di sensibilità alla presenza di valori anomali (*outlier*).

Indice	Tipo di carattere	Sensibile agli outlier?	Cosa rende minimo
Media $\bar{x}$	solo quantitativo	Sì, molto	la somma dei quadrati degli scarti (Teor. 2.2)
Mediana Me	quantitativo o ordinale	No, robusta	la somma delle distanze assolute (verificato sopra)
Moda Mo	qualsiasi (anche nominale)	dipende dai dati	– (è la modalità più frequente)

ESEMPIO — PERCHÉ LA MEDIANA È “ROBUSTA”: UN CONTROESEMPIO NUMERICO

Consideriamo gli stipendi mensili (in migliaia di euro) di 5 dipendenti: 1.5, 1.6, 1.8, 2.0, 2.1. Si ha $\bar{x} = \frac{1.5+1.6+1.8+2.0+2.1}{5} = \frac{9.0}{5} = 1.8$ e $Me = 1.8$: i due indici coincidono. Supponiamo ora che il quinto dipendente sia in realtà il direttore, con stipendio 20.0 (anziché 2.1): la mediana resta *invariata*, $Me = 1.8$ (è ancora il valore centrale), mentre la media “esplode” a $\bar{x} = \frac{1.5+1.6+1.8+2.0+20.0}{5} = \frac{26.9}{5} = 5.38$, un valore che *nessuno* dei restanti quattro dipendenti percepisce nemmeno lontanamente. In presenza di valori anomali, la mediana descrive la situazione “tipica” molto meglio della media.

2.3 Indici di variabilità (dispersione)

Due distribuzioni possono avere *esattamente la stessa media* ed essere, tuttavia, profondamente diverse: si pensi a due classi che ottengono entrambe una media del 6 in matematica, ma nella prima tutti gli studenti prendono 6, mentre nella seconda metà classe prende 3 e metà prende 9. Gli indici di **posizione centrale**, da soli, non colgono questa differenza: servono **indici di variabilità** (o di *dispersione*) che misurino quanto i dati siano concentrati o sparsi attorno al centro.

DEFINIZIONE 2.8: Campo di Variazione (Range)

Si definisce **campo di variazione** (o *range*) la differenza tra il valore massimo e il valore minimo osservati:

$$R = x_{\max} - x_{\min}.$$

ATTENZIONE — IL LIMITE DEL CAMPO DI VARIAZIONE

Il range è un indice estremamente semplice ma anche estremamente *fragile*: dipende soltanto da due dati (i due estremi) e ignora completamente come sono distribuiti tutti gli altri dati. Due distribuzioni con lo stesso range possono avere variabilità interna radicalmente diversa. Per questo motivo il range si affianca sempre a indici più robusti come la deviazione standard.

DEFINIZIONE 2.9: Varianza e Deviazione Standard

Data una serie di N dati $x_1, \dots, x_N$ con media $\bar{x}$, si definisce **varianza** la media aritmetica dei quadrati degli scarti dei dati dalla loro media:

$$\sigma^2 = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_N - \bar{x})^2}{N}.$$

Se i dati sono raccolti in una tabella di frequenza (valori distinti $x_1, \dots, x_k$ con frequenze $n_1, \dots, n_k$), la formula equivalente è

$$\sigma^2 = \frac{n_1(x_1 - \bar{x})^2 + n_2(x_2 - \bar{x})^2 + \dots + n_k(x_k - \bar{x})^2}{N}.$$

Si definisce **deviazione standard** (o *scarto quadratico medio*) la radice quadrata aritmetica, positiva, della varianza:

$$\sigma = \sqrt{\sigma^2} \geq 0.$$

ATTENZIONE — PERCHÉ ELEVARE AL QUADRATO, E PERCHÉ POI ESTRARRE LA RADICE

Se semplicemente sommassimo gli scarti $x_i - \bar{x}$, otterremmo sempre 0 per il Teorema 2.1: gli scarti positivi e negativi si annullerebbero a vicenda, mascherando la variabilità reale. Elevando al quadrato, ogni scarto diventa non negativo (indipendentemente dal segno originario) ed *eliminiamo* così le cancellazioni, ottenendo un indice sempre ≥ 0 e nullo se e solo se tutti i dati coincidono con la media (cioè sono tutti uguali tra loro). L'estrazione della radice quadrata nella deviazione standard σ non è un capriccio estetico, ma una necessità dimensionale: se i dati x_i sono espressi, ad esempio, in centimetri, la varianza σ^2 si misura in *centimetri quadrati*, un'unità priva di significato intuitivo per descrivere una dispersione lineare; la deviazione standard σ , riportando l'indice alla stessa unità di misura dei dati originali, è invece direttamente confrontabile con essi.

TEOREMA 2.3: Una formula di calcolo più comoda per la varianza

Vale sempre l'identità

$$\sigma^2 = (\text{media dei quadrati dei dati}) - (\text{quadrato della media dei dati}),$$

cioè, scrivendo per esteso,

$$\sigma^2 = \frac{x_1^2 + x_2^2 + \dots + x_N^2}{N} - \bar{x}^2.$$

DIMOSTRAZIONE. Per ciascun dato x_i vale l'identità algebrica (sviluppo del quadrato di un binomio):

$$(x_i - \bar{x})^2 = x_i^2 - 2\bar{x}x_i + \bar{x}^2.$$

Scriviamo questa relazione per tutti N dati e sommiamo membro a membro:

$$(x_1 - \bar{x})^2 + \dots + (x_N - \bar{x})^2 = (x_1^2 + \dots + x_N^2) - 2\bar{x}(x_1 + \dots + x_N) + \underbrace{(\bar{x}^2 + \dots + \bar{x}^2)}_{N \text{ volte}}.$$

Dividiamo tutto per N . Il membro sinistro diviso N è, per definizione, σ^2 . A destra: il primo gruppo diviso N è la media dei quadrati; nel secondo gruppo riconosciamo $\frac{x_1 + \dots + x_N}{N} = \bar{x}$, quindi quel termine diventa $2\bar{x} \cdot \bar{x} = 2\bar{x}^2$; il terzo gruppo diviso N vale semplicemente $\bar{x}^2$. In totale:

$$\sigma^2 = (\text{media dei quadrati}) - 2\bar{x}^2 + \bar{x}^2 = (\text{media dei quadrati}) - \bar{x}^2.$$

■

ATTENZIONE — UN FATTO INTERESSANTE CHE SEGUE SUBITO DA QUESTO TEOREMA

Poiché la varianza σ^2 è per definizione una media di quadrati, non può mai essere negativa: $\sigma^2 \geq 0$ sempre. Combinando questo con il Teorema 2.3 scopriamo che **la media dei quadrati dei dati è sempre maggiore o uguale al quadrato della loro media**, con uguaglianza soltanto quando tutti i dati coincidono (varianza nulla). Prova a verificarlo su un insieme di numeri a tua scelta: non è mai possibile che il quadrato della media superi la media dei quadrati.

ESEMPIO — VERIFICA NUMERICA DELLA FORMULA PIÙ COMODA

Riprendiamo l'esempio guida ($N = 15, \bar{x} = \frac{104}{15}$). Calcoliamo la somma dei quadrati di tutti i 15 voti, usando la tabella di frequenza:

$$1 \cdot 4^2 + 2 \cdot 5^2 + 3 \cdot 6^2 + 4 \cdot 7^2 + 2 \cdot 8^2 + 2 \cdot 9^2 + 1 \cdot 10^2 = 16 + 50 + 108 + 196 + 128 + 162 + 100 = 760.$$

Applicando il Teorema 2.3:

$$\sigma^2 = \frac{760}{15} - \left(\frac{104}{15}\right)^2 = 50.\bar{6} - 48.07\bar{1} \approx 2.60 \quad \Rightarrow \quad \sigma = \sqrt{2.60} \approx 1.61.$$

Il lettore è invitato a verificare che si ottiene *esattamente* lo stesso risultato calcolando direttamente σ^2 a partire dagli scarti individuali dalla media: la formula di questo teorema è preferibile in pratica perché richiede un solo "passaggio" sui dati (si accumulano contemporaneamente la somma dei dati e la somma dei loro quadrati), senza dover prima calcolare $\bar{x}$ per poi ricalcolare ogni singolo scarto.

TEOREMA 2.4: Effetto di Traslazioni e Cambiamenti di Scala

Siano $x_1, \dots, x_N$ dati con media $\bar{x}$ e varianza σ_x^2 ; siano a, b numeri fissati, con $a \neq 0$, e definiamo la nuova serie di dati trasformata linearmente

$$y_i = a x_i + b, \quad i = 1, \dots, N.$$

Allora:

$$\bar{y} = a\bar{x} + b \quad \text{e} \quad \sigma_y^2 = a^2 \sigma_x^2 \quad (\text{quindi } \sigma_y = |a| \sigma_x).$$

DIMOSTRAZIONE. *Media.* Sommando tutti i $y_i = a x_i + b$ e dividendo per N :

$$\bar{y} = \frac{(ax_1 + b) + (ax_2 + b) + \dots + (ax_N + b)}{N} = \frac{a(x_1 + \dots + x_N)}{N} + \frac{Nb}{N} = a\bar{x} + b.$$

Varianza. Calcoliamo lo scarto di y_i dalla propria media $\bar{y}$, usando il risultato appena trovato:

$$y_i - \bar{y} = (ax_i + b) - (a\bar{x} + b) = a(x_i - \bar{x}).$$

Elevando al quadrato: $(y_i - \bar{y})^2 = a^2(x_i - \bar{x})^2$. Scriviamo questa relazione per tutti gli N dati, sommiamo e dividiamo per N :

$$\sigma_y^2 = \frac{(y_1 - \bar{y})^2 + \cdots + (y_N - \bar{y})^2}{N} = \frac{a^2[(x_1 - \bar{x})^2 + \cdots + (x_N - \bar{x})^2]}{N} = a^2\sigma_x^2.$$

Infine, essendo la deviazione standard la radice quadrata aritmetica (non negativa) della varianza, e ricordando che $\sqrt{t^2} = |t|$ per ogni numero reale t :

$$\sigma_y = \sqrt{\sigma_y^2} = \sqrt{a^2\sigma_x^2} = \sqrt{a^2} \cdot \sqrt{\sigma_x^2} = |a| \cdot \sigma_x.$$

■

ATTENZIONE — INTERPRETAZIONE PRATICA E UN'INSIDIA DA EVITARE

Traslare tutti i dati di una costante b (ad esempio, aggiungere 1 punto di bonus a tutti i voti) *non altera* la variabilità della distribuzione: σ resta identica, perché ogni dato si sposta “in blocco” insieme alla propria media, lasciando invariate le distanze reciproche. **Cambiare l'unità di misura** (ad esempio, convertire delle lunghezze da metri a centimetri, cioè $a = 100$) moltiplica invece la deviazione standard per il fattore di scala $|a|$: attenzione, non basta moltiplicare la varianza per a , bisogna moltiplicarla per a^2 (errore molto comune, si veda la Sezione 3).

ATTENZIONE — CENNO ALLA DEVIATION STANDARD CAMPIONARIA: LA CORREZIONE DI BESSEL

Quando i dati $x_1, \dots, x_N$ non sono l'intera popolazione ma un *campione* estratto da essa (Definizione 2.1), e si vuole *stimare* la variabilità dell'intera popolazione a partire dal campione, si utilizza spesso la **varianza campionaria corretta**

$$s^2 = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \cdots + (x_N - \bar{x})^2}{N - 1}$$

al posto della varianza “diretta” con N a denominatore. Il motivo di questa correzione (nota come *correzione di Bessel*) è che il campione tende, in media, a sottostimare leggermente la vera variabilità della popolazione da cui proviene; la spiegazione precisa di questo fatto richiederà strumenti di probabilità che vedremo più avanti. In questa sede è sufficiente saper riconoscere quando un problema richiede N (variabilità dell'intero insieme di dati a disposizione) e quando richiede $N - 1$ (stima della variabilità di una popolazione più ampia a partire da un campione).

DEFINIZIONE 2.10: Coefficiente di Variazione

Si definisce **coefficiente di variazione** il rapporto (spesso espresso in percentuale)

$$CV = \frac{\sigma}{\bar{x}} \quad (\text{con } \bar{x} \neq 0),$$

che misura la variabilità *relativa* dei dati rispetto al loro valore medio, rendendola indipendente dall'unità di misura. È l'indice corretto da utilizzare per confrontare la dispersione di due distribuzioni espresse in unità di misura diverse, oppure con medie molto differenti tra loro.

ESEMPIO — PERCHÉ NON SI PUÒ CONFRONTARE DIRETTAMENTE σ

Supponiamo di voler confrontare la variabilità del peso alla nascita dei neonati ($\bar{x} = 3.3$ kg, $\sigma = 0.4$ kg) con quella del peso corporeo di elefanti adulti ($\bar{x} = 4000$ kg, $\sigma = 300$ kg). Confrontare direttamente le deviazioni standard (0.4 contro 300) è privo di significato, perché le scale sono radicalmente diverse. I coefficienti di variazione, invece, sono numeri puri e confrontabili:

$$CV_{\text{neonati}} = \frac{0.4}{3.3} \approx 0.121 = 12.1\%, \quad CV_{\text{elefanti}} = \frac{300}{4000} = 0.075 = 7.5\%.$$

Sorprendentemente, il peso dei neonati è *relativamente* più variabile di quello degli elefanti adulti, nonostante la deviazione standard assoluta sia enormemente più piccola.

2.4 Rappresentazione grafica dei dati


Accanto agli indici numerici, la statistica descrittiva dispone di strumenti **grafici** che permettono di cogliere a colpo d'occhio la forma di una distribuzione. La scelta del grafico corretto dipende dal tipo di carattere.

DEFINIZIONE 2.11: Diagramma a Barre

Usato per caratteri **qualitativi** o **quantitativi discreti**: sull'asse orizzontale si riportano le modalità (separate, non contigue), sull'asse verticale le frequenze (assolute o relative); a ciascuna modalità corrisponde una barra di altezza proporzionale alla frequenza. È il grafico utilizzato in Sezione 1.4 per i voti della classe.

DEFINIZIONE 2.12: Istogramma

Usato per caratteri **quantitativi continui**, i cui dati vengono preliminarmente raggruppati in **classi** (intervalli contigui, tipicamente di uguale ampiezza). A differenza del diagramma a barre, nell'istogramma le barre sono *contigue* (senza spazi), a sottolineare la continuità della variabile, e — aspetto cruciale quando le classi hanno ampiezze diverse — è l'**area** di ciascun rettangolo, e non la sola altezza, a dover essere proporzionale alla frequenza della classe.



DEFINIZIONE 2.13: Areogramma (Diagramma a Torta)

Usato prevalentemente per caratteri **qualitativi**, rappresenta ciascuna modalità come un settore circolare di un cerchio, la cui ampiezza angolare α_i è proporzionale alla frequenza relativa f_i :


$$\alpha_i = f_i \cdot 360^\circ.$$

ESEMPIO

Se il 25% degli studenti di un istituto sceglie l'indirizzo scientifico, il settore corrispondente occuperà $\alpha = 0.25 \cdot 360^\circ = 90^\circ$, cioè un quarto esatto del cerchio.

DEFINIZIONE 2.14: Diagramma a Scatola (Box-Plot) e Quartili

Il **box-plot** sintetizza graficamente cinque valori notevoli di una distribuzione ordinata: il minimo $x_{\min}$, il **primo quartile** Q_1 , la **mediana** $Q_2 = Me$, il **terzo quartile** Q_3 e il massimo $x_{\max}$. I quartili sono i tre valori che suddividono i dati ordinati in quattro parti di uguale numerosità (circa il 25% dei dati in ciascuna parte): Q_1 è la mediana della "prima metà" dei dati, Q_3 è la mediana della "seconda metà". Graficamente, un rettangolo (la "scatola") si estende da Q_1 a Q_3 – racchiudendo il cosiddetto 50% centrale dei dati – con una linea interna in corrispondenza della mediana, mentre due segmenti (i "baffi") si protendono fino a $x_{\min}$ e $x_{\max}$.



ATTENZIONE — UNA PRECISAZIONE: DUE CONVENZIONI PER I "BAFFI"

La versione qui presentata, con i baffi che raggiungono direttamente $x_{\min}$ e $x_{\max}$, è la convenzione più semplice ed è quella adottata in questa dispensa. Esiste tuttavia una convenzione alternativa, molto usata in ambito scientifico e nel software statistico, in cui i baffi si arrestano al più a una distanza pari a $1.5 \cdot (Q_3 - Q_1)$ dalla scatola: gli eventuali dati che superano tale soglia vengono segnati singolarmente come possibili **valori anomali** (*outlier*). Le due convenzioni

coincidono quando non vi sono dati particolarmente estremi.

ATTENZIONE — IL BOX-PLOT COME STRUMENTO DI CONFRONTO

Il vero punto di forza del box-plot emerge quando se ne disegnano *più di uno affiancati* (ad esempio, uno per ciascuna classe di uno stesso istituto): la larghezza della scatola comunica immediatamente la variabilità centrale dei dati, mentre la posizione della linea mediana all'interno della scatola rivela eventuali asimmetrie — informazioni che una singola media, da sola, non potrebbe mai trasmettere con altrettanta immediatezza visiva.

FORMULARIO — INDICI DI STATISTICA DESCRITTIVA

- **Media aritmetica:** $\bar{x} = \frac{x_1 + x_2 + \dots + x_N}{N} = f_1x_1 + f_2x_2 + \dots + f_kx_k$
- **Mediana:** il dato di mezzo se N è dispari; la media dei due dati centrali se N è pari
- **Moda:** modalità di massima frequenza
- **Campo di variazione:** $R = x_{\max} - x_{\min}$
- **Varianza:** $\sigma^2 = \frac{(x_1 - \bar{x})^2 + \dots + (x_N - \bar{x})^2}{N} = \frac{x_1^2 + \dots + x_N^2}{N} - \bar{x}^2$
- **Deviazione standard:** $\sigma = \sqrt{\sigma^2}$
- **Varianza campionaria corretta:** $s^2 = \frac{(x_1 - \bar{x})^2 + \dots + (x_N - \bar{x})^2}{N - 1}$
- **Coefficiente di variazione:** $CV = \frac{\sigma}{\bar{x}}$
- **Effetto di $y_i = ax_i + b$:** $\bar{y} = a\bar{x} + b, \quad \sigma_y = |a| \sigma_x$

ERRORI TIPICI, METODO ED ESERCIZI SVOLTI

Dalle trappole più insidiose alle strategie risolutive, fino alla pratica guidata

3 CASI LIMITE, TRAPPOLE ED ERRORI TIPICI

Gran parte degli errori commessi nei compiti in classe e nelle verifiche di statistica descrittiva non nasce da un'incomprensione dei concetti, bensì da una **disattenzione procedurale**: un'ipotesi trascurata, un ordinamento saltato, un fattore di scala applicato in modo scorretto. In questa sezione analizziamo, uno per uno, gli errori più frequenti, ciascuno corredato da un **controesempio numerico** che ne mostra concretamente le conseguenze.

ATTENZIONE — ERRORE TIPICO 1 — APPLICARE LA MEDIA A UN CARATTERE QUALITATIVO

L'errore. Assegnare arbitrariamente dei codici numerici a categorie non ordinabili e calcolarne poi "la media", attribuendo a tale numero un significato che non possiede.

Controesempio. Il colore degli occhi di 5 studenti è: marrone, marrone, verde, azzurro, marrone. Codificando arbitrariamente marrone= 1, verde= 2, azzurro= 3, si otterrebbe una "media" pari a $\frac{1+1+2+3+1}{5} = 1.6$. Questo numero non corrisponde a nessun colore reale, e soprattutto *dipenderebbe totalmente dall'ordine arbitrario* con cui abbiamo scelto di numerare i colori: assegnando azzurro= 1, marrone= 2, verde= 3 il risultato cambierebbe radicalmente, pur descrivendo esattamente lo stesso fenomeno.

La correzione. Per un carattere qualitativo nominale l'unico indice di posizione centrale sensato è la **moda** (Definizione 2.7): in questo caso, marrone (frequenza 3 su 5).

ATTENZIONE — ERRORE TIPICO 2 — CALCOLARE LA MEDIANA SENZA ORDINARE I DATI

L'errore. Individuare "il valore centrale" semplicemente contando la posizione dei dati *nell'ordine in cui sono stati raccolti o scritti*, senza prima disporli in ordine crescente.

Controesempio. Cinque voti vengono trascritti nell'ordine di correzione dei compiti: 8, 3, 9, 5, 6. Un errore molto comune consiste nel dichiarare mediana il terzo valore *così come scritto*, cioè 9. Il procedimento corretto richiede invece di ordinare prima i dati: 3, 5, 6, 8, 9; il valore centrale (terza posizione) è $Me = 6$, ben diverso da 9.

La correzione. L'ordinamento crescente dei dati (Definizione 2.6) è un passaggio *obbligatorio e non aggirabile* nel calcolo della mediana: non esiste alcuna scorciatoia che ne faccia a meno.

ATTENZIONE — ERRORE TIPICO 3 — N PARI: DIMENTICARE LA MEDIA DEI DUE VALORI CENTRALI

L'errore. Quando N è pari, scegliere *uno solo* dei due valori centrali (spesso per una lettura frettolosa della tabella), anziché calcolarne la media.

Controesempio. Dati ordinati 4, 6, 7, 9 ($N = 4$). I due valori centrali sono 6 e 7: la mediana corretta è $Me = \frac{6+7}{2} = 6.5$. Dichiarare $Me = 6$ oppure $Me = 7$ costituisce un errore, per quanto ciascuno dei due valori sia “vicino” alla risposta corretta: in un esercizio con richiesta di precisione (o in un problema a risposta multipla che distingua apposta tra 6, 6.5 e 7) tale imprecisione risulta un errore pieno.

ATTENZIONE — ERRORE TIPICO 4 — ISTOGRAMMI CON CLASSI DI AMPIEZZA DIVERSA: ALTEZZA CONTRO DENSITÀ

L'errore. Quando le classi di un istogramma hanno **ampiezze diverse**, disegnare le barre con altezza pari alla sola frequenza assoluta (o relativa), ignorando la correzione per l'ampiezza della classe richiesta dalla Definizione 2.12 (area proporzionale alla frequenza).

Controesempio. Un'indagine sui tempi di attesa (in minuti) a uno sportello raggruppa i dati in due sole classi: $[0, 10)$ con frequenza assoluta $n_1 = 20$, e $[10, 40)$ con frequenza assoluta $n_2 = 45$. Disegnando le barre con altezza pari alla frequenza assoluta, la seconda barra (45) risulterebbe più che doppia della prima (20), suggerendo (erroneamente) che i tempi di attesa si concentrino soprattutto nella fascia $[10, 40)$. Calcolando invece la corretta densità di frequenza $n_i/\text{ampiezza}_i$:

$$\text{densità}_{[0,10)} = \frac{20}{10} = 2 \text{ studenti/minuto}, \quad \text{densità}_{[10,40)} = \frac{45}{30} = 1.5 \text{ studenti/minuto},$$

si scopre che è in realtà la *prima* classe $[0, 10)$ ad avere la maggiore concentrazione di osservazioni per unità di tempo, cioè la vera classe modale in termini di densità.

La correzione. Con classi di ampiezza diversa, l'altezza *corretta* di ciascuna barra dell'istogramma è la densità di frequenza $n_i/\text{ampiezza}_i$ (o $f_i/\text{ampiezza}_i$), mai la sola frequenza assoluta o relativa.

ATTENZIONE — ERRORE TIPICO 5 — CONFONDERE LA VARIANZA σ^2 CON LA VARIANZA CAMPIONARIA s^2

L'errore. Applicare meccanicamente la formula con N a denominatore anche quando il problema richiede esplicitamente una *stima* della variabilità di una popolazione a partire da un campione (per cui servirebbe $N - 1$), o viceversa.

Controesempio. Un campione di 5 misurazioni fornisce i dati 12, 14, 15, 17, 20, con media $\bar{x} = 15.6$. La somma dei quadrati degli scarti dalla media vale 37.2. Si ottiene:

$$\sigma^2 = \frac{37.2}{5} = 7.44 \quad (\sigma \approx 2.73) \quad \text{contro} \quad s^2 = \frac{37.2}{4} = 9.3 \quad (s \approx 3.05).$$

I due risultati differiscono in modo non trascurabile (circa il 25% in più per la varianza), e usare l'uno al posto dell'altro nel contesto sbagliato produce una

stima errata della variabilità, pur partendo dagli stessi dati e dagli stessi calcoli intermedi.

La correzione. Prima di dividere, chiedersi sempre: *ho a disposizione l'intera popolazione di interesse (uso N), oppure sto usando un campione per stimare la variabilità di una popolazione più ampia (uso $N - 1$)?*

ATTENZIONE — ERRORE TIPICO 6 — CAMBIAMENTO DI SCALA: MOLTIPLICARE LA VARIANZA PER a ANZICHÉ PER a^2

L'errore. Nell'applicare il Teorema 2.4, moltiplicare erroneamente la varianza (anziché la deviazione standard) per il fattore di scala a , dimenticando l'elevamento al quadrato.

Controesempio. Quattro lunghezze, misurate in metri, sono 2, 4, 6, 8: si ha $\bar{x} = 5$ m e $\sigma^2 = 5$ m². Convertendo in centimetri ($a = 100$), i dati diventano 200, 400, 600, 800, con $\bar{x} = 500$ cm e, per calcolo diretto, $\sigma^2 = 50\,000$ cm². Applicando erroneamente "varianza $\times a$ " si otterrebbe $5 \times 100 = 500$ cm²: un risultato *cento volte più piccolo* di quello corretto. La formula corretta, $\sigma_y^2 = a^2 \sigma_x^2$, dà invece $100^2 \times 5 = 10\,000 \times 5 = 50\,000$ cm², in perfetto accordo con il calcolo diretto.

La correzione. È la deviazione standard (non la varianza) a scalare linearmente col fattore $|a|$; la varianza, essendo una misura "al quadrato", scala sempre con a^2 .

ATTENZIONE — ERRORE TIPICO 7 — SOMMARE LE DEVIAZIONI STANDARD DI DUE GRUPPI

L'errore. Pensare che, unendo due gruppi di dati, la deviazione standard (o la varianza) del gruppo complessivo sia semplicemente la media delle deviazioni standard (o delle varianze) dei singoli gruppi.

Perché è falso. La variabilità del gruppo unito dipende non solo dalla variabilità *interna* a ciascun gruppo, ma anche da quanto le *medie* dei due gruppi differiscono tra loro. Due gruppi con la stessa variabilità interna ma medie molto distanti producono, una volta uniti, una variabilità complessiva ben maggiore della semplice media pesata delle varianze originarie. Scopriremo questo fenomeno con un esempio concreto nell'Esercizio 5 (Sezione 5).

4 SCHEMI METODOLOGICI E ALGORITMI DI RISOLUZIONE

Questa sezione raccoglie, in forma di **check-list operativa**, le procedure da seguire per affrontare senza esitazioni le tipologie di esercizio più comuni.

ALGORITMO 1 — COSTRUIRE CORRETTAMENTE UNA TABELLA DI FREQUENZA

1. **Identifica il tipo di carattere** (qualitativo nominale/ordinale, quantitativo discreto/continuo): da questo dipende quali indici avranno senso calcolare (si veda l'attbox nella Sezione 2.1).
2. **Elenca le modalità distinte** presenti nei dati. Se il carattere è quantitativo

continuo con molti valori distinti, raggruppa i dati in **classi** contigue (tipicamente di uguale ampiezza, salvo esigenze specifiche).

3. **Conta le frequenze assolute** n_i di ciascuna modalità (o classe), verificando sempre che la loro somma dia N .
4. **Calcola frequenze relative e percentuali** $f_i = n_i/N$, verificando che la loro somma dia 1 (a meno di arrotondamenti).
5. Se richiesto, **calcola le frequenze cumulate**, ricordando che ha senso farlo solo se le modalità sono ordinabili.

ALGORITMO 2 — SCEGLIERE L'INDICE DI POSIZIONE CENTRALE PIÙ OPPORTUNO

1. Se il carattere è **qualitativo nominale**, l'unico indice disponibile è la **moda**: usala.
2. Se il carattere è **quantitativo o ordinale**, controlla se sono presenti **valori anomali (outlier)** evidenti (dati molto distanti dal resto): in tal caso preferisci la **mediana**, più robusta.
3. Se i dati sono **omogenei** (senza outlier evidenti) e il carattere è quantitativo, la **media** è generalmente l'indice più informativo, poiché sintetizza il contributo di *ogni* dato (a differenza della mediana, che dipende solo dall'ordinamento).
4. In un esercizio, quando non è specificato quale indice usare, è buona norma **calcolarli tutti e confrontarli**: la loro eventuale distanza è già di per sé un'informazione preziosa sulla forma della distribuzione (si veda la Sezione 2.2.4).

ALGORITMO 3 — CALCOLARE VARIANZA E DEVIATIONE STANDARD SENZA ERRORI

1. **Decidi se ti servono N o $N - 1$ a denominatore** (si veda l'Errore Tipico 5): stai descrivendo l'intero insieme di dati a disposizione (N), oppure stimando la variabilità di una popolazione più ampia da un campione ($N - 1$)?
2. **Calcola la media $\bar{x}$** con tutte le cifre decimali necessarie (evita di arrotondare la media prima di usarla nei passaggi successivi: l'arrotondamento prematuro introduce errori di propagazione).
3. **Scegli la formula di calcolo più efficiente**: per dati grezzi non raggruppati, la formula "media dei quadrati meno quadrato della media" (Teorema 2.3) richiede un solo passaggio sui dati ed è generalmente più rapida della formula diretta con gli scarti.
4. **Estrai la radice quadrata solo alla fine**, dopo aver ottenuto la varianza, per ottenere la deviazione standard.
5. Se il problema prevede una **trasformazione lineare** dei dati ($y_i = ax_i + b$), non

ricalcolare tutto da capo: applica direttamente il Teorema 2.4 ($\bar{y} = a\bar{x} + b$, $\sigma_y = |a|\sigma_x$), prestando attenzione all'Errore Tipico 6.

ALGORITMO 4 — COSTRUIRE UN ISTOGRAMMA CON CLASSI DI AMPIEZZA DIVERSA

1. Suddividi i dati nelle classi richieste e calcola l'ampiezza w_i di ciascuna classe.
2. Calcola la **densità di frequenza** $d_i = n_i/w_i$ (oppure f_i/w_i) per ciascuna classe.
3. Disegna ogni barra con **altezza pari alla densità** d_i (mai alla sola frequenza, salvo il caso particolare in cui tutte le classi abbiano la stessa ampiezza, nel qual caso le due scelte sono equivalenti a meno di un fattore di scala comune).
4. Verifica il risultato: l'**area totale** dell'istogramma (somma delle aree di tutti i rettangoli) deve essere pari a N (se hai usato le frequenze assolute) o a 1 (se hai usato le frequenze relative).
5. La **classe modale** è quella con la densità d_i più elevata, non necessariamente quella con la frequenza assoluta più elevata (si veda l'Errore Tipico 4).

ALGORITMO 5 — COSTRUIRE UN BOX-PLOT

1. Ordina tutti i dati in ordine crescente.
2. Individua $x_{\min}$, $x_{\max}$ e la **mediana** Me (Definizione 2.6).
3. Calcola Q_1 come mediana della "prima metà" dei dati (i valori strettamente a sinistra di Me , esclusa Me stessa se N è dispari), e Q_3 come mediana della "seconda metà".
4. Disegna il rettangolo (la scatola) da Q_1 a Q_3 , traccia la linea interna in corrispondenza di Me , ed estendi i baffi fino a $x_{\min}$ e $x_{\max}$ (o, in alternativa, fino a $1.5 \cdot (Q_3 - Q_1)$ dalla scatola, segnando singolarmente gli eventuali outlier: si veda la precisazione nella Sezione 2.4).

5 ESERCIZI SVOLTI E COMMENTATI**ESERCIZIO 5.1 — Calcolo degli indici fondamentali (con discussione dei segni)****LIVELLO: BASE**

Testo. In una città vengono rilevate le seguenti temperature (in °C) in 7 momenti diversi della giornata:

$$-5, -3, -1, 1, 3, 5, 7.$$

Calcola media, mediana, moda, campo di variazione, varianza e deviazione standard.

MEDIA

I dati sono già ordinati e $N = 7$. Sommiamo con attenzione, tenendo conto dei segni:

$$(-5) + (-3) + (-1) + 1 + 3 + 5 + 7 = 7 \quad \Rightarrow \quad \bar{x} = \frac{7}{7} = 1.$$

MEDIANA

$N = 7$ è dispari: il valore centrale è quello in posizione $\frac{7+1}{2} = 4$, cioè $Me = 1$. Si osservi che, in questo caso particolare, $Me = \bar{x} = 1$: ciò accade perché i dati formano una progressione aritmetica di ragione 2, quindi sono perfettamente simmetrici rispetto al valore centrale.

MODA

Ogni valore compare esattamente una volta: la distribuzione è **amodale** (nessun valore si ripete). Non tutte le distribuzioni possiedono una moda significativa.

CAMPO DI VARIAZIONE

$$R = x_{\max} - x_{\min} = 7 - (-5) = 12.$$

VARIANZA E DEVIAZIONE STANDARD

Calcoliamo con cura ogni scarto dalla media $\bar{x} = 1$, prestando particolare attenzione al segno, e successivamente il suo quadrato (che sarà sempre non negativo, indipendentemente dal segno dello scarto):

x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
-5	-6	36
-3	-4	16
-1	-2	4
1	0	0
3	2	4
5	4	16
7	6	36

La somma dei quadrati è $36 + 16 + 4 + 0 + 4 + 16 + 36 = 112$, dunque

$$\sigma^2 = \frac{112}{7} = 16 \quad \Rightarrow \quad \sigma = \sqrt{16} = 4 \text{ °C}.$$

$$\bar{x} = 1^\circ\text{C}, \quad \text{Me} = 1^\circ\text{C}, \quad \text{amodale}, \quad R = 12^\circ\text{C}, \quad \sigma^2 = 16 (\text{C})^2, \quad \sigma = 4^\circ\text{C}.$$

Commento didattico. Questo esercizio, pur meccanico, nasconde un'insidia tipica: la presenza di valori *negativi* tra i dati non altera in alcun modo la procedura, a patto di trattare i segni con la stessa cura che si userebbe in un qualsiasi calcolo algebrico. Si noti come gli scarti si compensino esattamente a due a due (-6 con $+6$, -4 con $+4$, -2 con $+2$), verificando concretamente che la somma di tutti gli scarti dalla media è zero (Teorema 2.1), mentre i loro quadrati, tutti non negativi, si sommano senza cancellazioni per fornire una misura di variabilità sempre positiva.

ESERCIZIO 5.2 — Discussione parametrica al variare di k

LIVELLO: INTERMEDIO

Testo. Le vendite mensili (in migliaia di euro) di un piccolo negozio nei primi cinque mesi dell'anno sono 8, 10, 11, 13, k , dove $k \geq 0$ rappresenta la vendita, ancora da consolidare, del quinto mese. Determina:

- per quali valori di k la media supera 11 (migliaia di euro);
- l'espressione della mediana in funzione di k , discutendo tutti i casi;
- per quali valori di k la distribuzione ammette una moda.

PUNTO (A): LA MEDIA IN FUNZIONE DI k

$$\bar{x}(k) = \frac{8 + 10 + 11 + 13 + k}{5} = \frac{42 + k}{5}.$$

Imponiamo $\bar{x}(k) > 11$:

$$\frac{42 + k}{5} > 11 \iff 42 + k > 55 \iff k > 13.$$

PUNTO (B): LA MEDIANA IN FUNZIONE DI k — DISCUSSIONE DEI CASI

Fissiamo i quattro valori noti già ordinati: 8, 10, 11, 13. Inserendo k in questa sequenza, la mediana (il terzo valore su cinque, una volta riordinati) dipende dalla posizione che k occupa rispetto a questi quattro numeri. Distinguiamo i casi:

- Se $k \leq 10$: l'ordinamento è $k, 8, 10, 11, 13$ (o $8, k, 10, 11, 13$ se $8 \leq k \leq 10$); in ogni caso il terzo valore resta 10. Dunque $\text{Me} = 10$.
- Se $10 \leq k \leq 11$: l'ordinamento è $8, 10, k, 11, 13$; il terzo valore è ora k stesso. Dunque $\text{Me} = k$.
- Se $k \geq 11$: l'ordinamento è $8, 10, 11, k, 13$ (o $8, 10, 11, 13, k$ se $k \geq 13$); in ogni caso il terzo valore resta 11. Dunque $\text{Me} = 11$.

Riassumendo:

$$\text{Me}(k) = \begin{cases} 10 & \text{se } 0 \leq k \leq 10 \\ k & \text{se } 10 \leq k \leq 11 \\ 11 & \text{se } k \geq 11 \end{cases}$$

Si noti che, passando da un caso all'altro, i valori si raccordano esattamente (10 per $k = 10$, 11 per $k = 11$): la mediana si muove "con" k solo nella fascia intermedia, mentre resta ferma agli estremi. È un comportamento tipico della mediana, che "ignora" le variazioni di un singolo dato una volta che questo si allontana a sufficienza dal centro della distribuzione.

PUNTO (c): QUANDO ESISTE UNA MODA

Per $k \notin \{8, 10, 11, 13\}$ tutti i cinque valori sono distinti: la distribuzione è amodale. Una moda esiste se e solo se k coincide con uno dei quattro valori già presenti: in tal caso quel valore compare con frequenza 2 (contro frequenza 1 degli altri) e diventa l'unica moda della distribuzione, pari a k stesso.

(a) $k > 13$; **(b)** $Me(k)$ definita a tratti come sopra; **(c)** esiste moda $\iff k \in \{8, 10, 11, 13\}$.

Commento didattico. Il punto (b) è il cuore concettuale dell'esercizio: a differenza della media, che cresce sempre insieme a k (è una funzione lineare di k), la mediana si muove solo quando k si trova già vicino al centro della distribuzione, e resta ferma non appena k si allontana troppo in una direzione o nell'altra. Questo è esattamente il fenomeno di robustezza già incontrato nella Sezione 2.2.2 (la mediana come minimo delle distanze assolute) e discusso nella Sezione 2.2.4: un singolo dato può crescere a piacere senza che la mediana se ne accorga, cosa impossibile per la media.

ESERCIZIO 5.3 — Tabella di frequenza, classe modale e traslazione

LIVELLO: AVANZATO

Testo. I punteggi (da 0 a 100) ottenuti da 40 studenti in un test d'ingresso sono raggruppati nella seguente tabella di frequenza a classi:

Classe	Valore centrale	Frequenza n_i
[0, 20)	10	3
[20, 40)	30	6
[40, 60)	50	12
[60, 80)	70	14
[80, 100]	90	5

- Calcola la media e la deviazione standard dei punteggi (usando il valore centrale di ciascuna classe come rappresentante).
- Individua la classe modale.
- La commissione decide di assegnare un bonus di 5 punti a tutti gli studenti. Determina la nuova media e la nuova deviazione standard, motivando il risultato senza rifare tutti i calcoli da capo.

PUNTO (A): MEDIA E DEVIAZIONE STANDARD

Verifichiamo anzitutto che la somma delle frequenze dia $3+6+12+14+5 = 40 = N$ ✓. Applichiamo la formula della media ponderata (Definizione 2.5):

$$\bar{x} = \frac{3 \cdot 10 + 6 \cdot 30 + 12 \cdot 50 + 14 \cdot 70 + 5 \cdot 90}{40} = \frac{30 + 180 + 600 + 980 + 450}{40} = \frac{2240}{40} = 56.$$

Per la deviazione standard usiamo il Teorema 2.3 (formula più comoda), calcolando prima la somma dei quadrati pesati:

$$\begin{aligned} & 3 \cdot 100 + 6 \cdot 900 + 12 \cdot 2500 + 14 \cdot 4900 + 5 \cdot 8100 \\ &= 300 + 5400 + 30000 + 68600 + 40500 = 144800, \end{aligned}$$

da cui

$$\sigma^2 = \frac{144800}{40} - 56^2 = 3620 - 3136 = 484 \quad \implies \quad \sigma = \sqrt{484} = 22.$$

PUNTO (B): CLASSE MODALE

La frequenza più alta è $n = 14$, corrispondente alla classe $[60, 80)$. Poiché tutte le classi hanno la **stessa ampiezza** (20 punti ciascuna), non è necessario alcun ricorso alla densità di frequenza (si veda l'Errore Tipico 4): la classe modale è semplicemente $[60, 80)$.

PUNTO (C): EFFETTO DEL BONUS

Assegnare un bonus fisso di 5 punti a *ogni* studente equivale ad applicare la trasformazione lineare $y_i = x_i + 5$ (cioè $a = 1, b = 5$) a tutti i dati. Per il Teorema 2.4:

$$\bar{y} = 1 \cdot \bar{x} + 5 = 56 + 5 = 61, \quad \sigma_y = |1| \cdot \sigma_x = 22.$$

Non è necessario rifare alcun calcolo sulle singole classi: una traslazione (bonus additivo uguale per tutti) sposta la media ma **lascia invariata la deviazione standard**, poiché ogni dato si sposta "in blocco" insieme alla propria media, senza alterare le distanze reciproche.

(a) $\bar{x} = 56, \sigma = 22$; **(b)** classe modale = $[60, 80)$; **(c)** $\bar{y} = 61, \sigma_y = 22$ (invariata).

Commento didattico. Il punto (c) è pensato per essere risolto *senza* ricalcolare l'intera tabella: riconoscere che un bonus uniforme è una traslazione, e richiamare direttamente il teorema già dimostrato nella Parte Prima, è precisamente il tipo di ragionamento sintetico ed efficiente che evita calcoli superflui e riduce il rischio di errore.

ESERCIZIO 5.4 — Misure ripetute in laboratorio: media, incertezza e outlier**LIVELLO: AVANZATO**

Testo. In un esperimento di fisica, il periodo di un pendolo viene misurato 8 volte con un cronometro, ottenendo i seguenti valori (in secondi):

2.01, 1.98, 2.03, 1.99, 2.00, 2.02, 1.97, 2.15.

- Calcola la media e la deviazione standard dell'intera serie di misure.
- Una delle misure appare sospetta. Individuala e, escludendola, ricalcola media e deviazione standard.
- Commenta l'effetto della misura sospetta sulla stima dell'incertezza sperimentale.

PUNTO (A): STATISTICHE SULL'INTERA SERIE

$$\bar{x} = \frac{2.01 + 1.98 + 2.03 + 1.99 + 2.00 + 2.02 + 1.97 + 2.15}{8} = \frac{16.15}{8} = 2.01875 \text{ s} \approx 2.019 \text{ s}.$$

Calcolando la varianza con la formula "media dei quadrati meno quadrato della media" si ottiene $\sigma^2 \approx 0.00281 \text{ s}^2$, dunque $\sigma \approx 0.053 \text{ s}$.

PUNTO (B): INDIVIDUAZIONE ED ESCLUSIONE DELL'OUTLIER

Osservando i dati, il valore 2.15 s si discosta vistosamente dagli altri sette (tutti compresi tra 1.97 e 2.03 s, un intervallo di appena 0.06 s): è ragionevole sospettare un errore di lettura del cronometro. Escludendolo, restano 7 misure:

$$\bar{x}' = \frac{2.01 + 1.98 + 2.03 + 1.99 + 2.00 + 2.02 + 1.97}{7} = \frac{14.00}{7} = 2.00 \text{ s} \quad (\text{esattamente!}).$$

Per la deviazione standard, la somma dei quadrati delle 7 misure vale 28.0028, da cui

$$\sigma'^2 = \frac{28.0028}{7} - 2.00^2 = 4.0004 - 4 = 0.0004 \text{ s}^2 \quad \Rightarrow \quad \sigma' = \sqrt{0.0004} = 0.02 \text{ s}.$$

Con tutte le misure: $\bar{x} \approx 2.019 \text{ s}$, $\sigma \approx 0.053 \text{ s}$. **Escludendo l'outlier:** $\bar{x}' = 2.00 \text{ s}$, $\sigma' = 0.02 \text{ s}$.

Commento didattico. Il confronto numerico è istruttivo: una *singola* misura anomala, su otto, sposta la stima della media di appena 0.019 s (meno dell'1% del valore vero), ma *quasi triplica* la deviazione standard, facendola passare da 0.02 s a 0.053 s (un fattore ≈ 2.65). Questo è un esempio fisico diretto dell'asimmetria, già discussa nella Sezione 2.2.4, tra la sensibilità della *media* agli outlier (moderata, perché l'errore di un solo dato su N si "diluiscie" nella somma) e quella della *varianza* (molto più marcata, perché lo scarto anomalo viene *elevato al quadrato* prima di essere mediato): un singolo dato sbagliato può quindi passare quasi inosservato nella media, pur alterando in modo sostanziale la stima dell'incertezza sperimentale. In un contesto sperimentale reale, l'esclusione di un dato sospetto andrebbe sempre motivata con un criterio oggettivo (ad esempio uno scarto superiore a qualche multiplo di σ) e non decisa arbitrariamente "a occhio".

ESERCIZIO 5.5 — La variabilità di due gruppi uniti: una scoperta guidata**LIVELLO: ESPERTO**

Testo. Due classi A e B sostengono la stessa verifica. La classe A è composta da 12 studenti, con media 7 e varianza 1.5; la classe B è composta da 18 studenti, con media 6 e varianza 2. Determina la media e la varianza dell'intero gruppo di 30 studenti (unendo le due classi), sapendo solo questi quattro numeri (non i singoli dati).

LA MEDIA DEL GRUPPO UNITO: NESSUNA SORPRESA

Immaginiamo di scrivere in fila tutti i 30 punteggi. I primi 12 (classe A) hanno somma $12 \times 7 = 84$, poiché la loro media è 7; gli altri 18 (classe B) hanno somma $18 \times 6 = 108$. La somma di tutti i 30 punteggi è quindi $84 + 108 = 192$, e la media del gruppo unito è

$$\bar{x} = \frac{192}{30} = 6.4.$$

Questo passaggio non nasconde insidie: la media si combina sempre in questo modo, pesando ciascuna media di gruppo con il proprio numero di studenti.

LA VARIANZA DEL GRUPPO UNITO: UNA SCOPERTA CON UN PICCOLO ESEMPIO

Ci si potrebbe aspettare, per analogia, che anche la varianza del gruppo unito sia semplicemente la media pesata delle due varianze, cioè $\frac{12 \times 1.5 + 18 \times 2}{30}$. Verifichiamo se questa idea è corretta con un esempio piccolo, dove possiamo controllare tutto a mano. Prendiamo un gruppo $A' = \{5, 7, 9\}$ e un gruppo $B' = \{4, 6\}$:

- Gruppo A' : media $= \frac{5+7+9}{3} = 7$; scarti $-2, 0, 2$; varianza $= \frac{4+0+4}{3} = \frac{8}{3} \approx 2.667$.
- Gruppo B' : media $= \frac{4+6}{2} = 5$; scarti $-1, 1$; varianza $= \frac{1+1}{2} = 1$.
- Media pesata delle due varianze (l'idea da verificare): $\frac{3 \times 2.667 + 2 \times 1}{5} = \frac{8 + 2}{5} = 2$.
- Ora uniamo davvero i due gruppi: $\{5, 7, 9, 4, 6\}$. La loro media è $\frac{5+7+9+4+6}{5} = \frac{31}{5} = 6.2$; gli scarti da 6.2 sono $-1.2, 0.8, 2.8, -2.2, -0.2$, con quadrati 1.44, 0.64, 7.84, 4.84, 0.04, di somma 14.8; la varianza vera è quindi $\frac{14.8}{5} = 2.96$.

Il valore vero (2.96) non coincide con la media pesata delle varianze (2): la nostra idea iniziale era sbagliata! La differenza è $2.96 - 2 = 0.96$. Da dove viene? Notiamo che le medie dei due gruppi (7 e 5) sono diverse dalla media generale (6.2): il gruppo A' sta 0.8 sopra la media generale, il gruppo B' sta 1.2 sotto. Proviamo a calcolare

$$\frac{3 \times (0.8)^2 + 2 \times (-1.2)^2}{5} = \frac{3 \times 0.64 + 2 \times 1.44}{5} = \frac{1.92 + 2.88}{5} = \frac{4.8}{5} = 0.96 :$$

è esattamente il pezzo mancante! Abbiamo scoperto che la *varianza del gruppo unito* è uguale alla *media pesata delle varianze interne*, più la *media pesata dei quadrati delle distanze tra le medie di gruppo e la media generale*. Il motivo intuitivo è il seguente: ogni dato del gruppo A' contribuisce alla varianza generale con la sua distanza dalla media *generale*, non dalla propria media di gruppo. Questa distanza si può scomporre in due pezzi (la distanza dalla propria media di gruppo, più la distanza tra le due medie): il primo pezzo, mediato su tutti i dati,

dà la varianza interna al gruppo; il secondo pezzo è uguale per tutti i dati dello stesso gruppo, e contribuisce quindi con il quadrato della distanza tra le medie.

APPLICHIAMO LA SCOPERTA AI DATI REALI DEL PROBLEMA

Usando lo stesso schema appena scoperto, con $n_A = 12$, $\bar{x}_A = 7$, $\sigma_A^2 = 1.5$ e $n_B = 18$, $\bar{x}_B = 6$, $\sigma_B^2 = 2$ (media generale $\bar{x} = 6.4$, già calcolata):

$$\text{parte "entro i gruppi"} = \frac{12 \times 1.5 + 18 \times 2}{30} = \frac{18 + 36}{30} = \frac{54}{30} = 1.8,$$

$$\begin{aligned} \text{parte "tra i gruppi"} &= \frac{12 \times (7 - 6.4)^2 + 18 \times (6 - 6.4)^2}{30} = \frac{12 \times 0.36 + 18 \times 0.16}{30} \\ &= \frac{4.32 + 2.88}{30} = \frac{7.2}{30} = 0.24. \end{aligned}$$

Sommando: $\sigma^2 = 1.8 + 0.24 = 2.04$, dunque $\sigma = \sqrt{2.04} \approx 1.43$.

$$\bar{x} = 6.4, \quad \sigma^2 = 2.04, \quad \sigma \approx 1.43.$$

Commento didattico. Questo esercizio mette in pratica l'Errore Tipico 7: la varianza del gruppo unito (2.04) non è la semplice media pesata delle varianze interne (1.8), ma questa più un termine aggiuntivo strettamente positivo (0.24) dovuto alla *distanza tra le medie* dei due gruppi. Solo se le due medie di gruppo fossero uguali questo termine si annullerebbe, e la varianza del gruppo unito si riduce esattamente alla media pesata delle varianze interne: un caso particolare che il lettore è invitato a verificare autonomamente con un esempio proprio. La strategia usata — scoprire la regola generale su un esempio piccolo e controllabile a mano, e poi applicarla con fiducia ai dati reali — è un metodo di lavoro potente, utilissimo ogni volta che una formula generale non è (ancora) disponibile.

FINE DELLA DISPENSA

Statistica Descrittiva — teoria chiara, esempi verificati ed esercizi svolti.

TOMMY.